大模型（LLMs）增量预训练篇

1. 为什么要增量预训练？

有一种观点，预训练学知识，指令微调学格式，强化学习对齐人类偏好，LIMA 等论文算是这一观点的证据。所以要想大模型有领域知识，得增量预训练。（靠指令微调记知识不靠谱，不是几十 w 条数据能做到的。）

2. 进行增量预训练 需要做哪些准备工作？

模型底座选型

主流是 LLaMA，因为 scaling 法则，可能 LLaMA 做了充分预训练。（当然有版权问题）
这里备选 BLOOM，感觉基座比 LLaMA 差，但是也有 7B 版本。
Falcon、CPM-bee、Aquila、Baichuan 待实验，license 友好，但生态和效果都是问题。其实，因为结构上都类似 LLaMA，未来估计会出现整合这些模型的项目。
（Falcon 公布的训练语料中没有中文）这里没列 ChatGLM 和 ChatGLM2，因为有种说法在 SFT 模型上增量预训练效果比较差。（未证实）

数据收集

这里最经典的开源预训练数据还是 wudao 的 200G 和 thepile 这两个数据集（怀念一下 Open-Llama）加起来有 1T 的文本量，足够前期玩耍了。
其实，刚开始实践的时候，不需要太多样本，先收集 GB 量级的领域文本跑通流程即可。

数据清洗

当然这里数据治理可能是 chatgpt 魔法的最关键的部分，最基础的是把网页爬取数据中的广告清理掉。Falcon 论文里介绍了数据清洗的手段，对于我们很有参考意义。

3. 增量预训练 所用训练框架？

超大规模训练

如果是真大规模炼丹，那没什么好说的，直接 3D 并行。

Megatron-Deepspeed 拥有多个成功案例，炼 LLaMA 可以参考 LydiaXiaohongLi 大佬的实现。（实在太强）

https://github.com/microsoft/Megatron-DeepSpeed/pull/139

炼 BLOOM 可以直接找到 Bigscience 的 git 仓库。

然而，转 checkpoint 还是挺费劲的。

少量节点训练

小门小户一共就几台机器几张卡的话，3D 并行有点屠龙术了。

张量并行只有在 nvlink 环境下才会起正向作用，但提升也不会太明显。

可以分 2 种情况：

单节点或者多节点（节点间通信快）：直接 deepspeed ZeRO 吧。（笔者用了 linly 的增量预训练代码，但有能力的最好用其他代码）比如，Open-Llama 的 fork 版本。

https://github.com/RapidAI/Open-Llama

多节点（但节点间通信慢）：考虑用流水线并行，参考另一个大佬的实现。

https://github.com/HuangLK/transpeeder

少量卡训练

如果资源特别少，显存怎么也不够，可以上 LoRA。

https://github.com/shibing624/MedicalGPT

4. 增量预训练 训练流程 是怎么样？

数据预处理

参考 LLaMA 的预训练长度，也把数据处理成 2048 长度（如果不够，做补全）
这里要吐槽，tencentpretrain 数据处理脚本的默认长度竟然是 128。

分词器

有很多工作加 LLaMA 中文词表，但是考虑到没有定论说加中文词表会更好，先用原版的吧，500k 的 tokenizer.model。
https://github.com/ymcui/Chinese-LLaMA-Alpaca

原始模型

可以使用一个中文增量预训练后的版本，当然这里坑挺大的，各家框架的模型层名不太一样。
为了快速跑通，用脚本快速转一下，能成功加载就行。

训练参数

如果显存不够，可以 zero3+offload。其他参数暂时默认吧。（事实上没有想象中慢）
多机的话可以配一下 deepspeed 的 hostfile。

观测训练进展

这一点可能是最重要的，跑通只是第一步，根据训练情况反复调整比较重要。
可以使用 wandb，记录 loss，flops，吞吐速度，已消耗的 token 数，和测试 ppl。

模型转换

不同框架的 checkpoint 格式不同，还会根据并行度分成很多个文件。
以 ZeRO 为例，我的转换流程（很挫）是：
zero to f32
f32 to fp16
fp16 to huggingface 格式

模型测试

转为标准 huggingface 格式后可以用各种支持 llama 的前端加载，比如 text-generation-webui。
可以简单测试下续写能力，验证下模型是否正常。
至此，我们获得了 1 个增量预训练过的大模型基座。

5. 增量预训练一般需要多大数据量？

首先要确保你有足够大量的数据集，至少有几 B 的 token；否则几十条数据的情况我更推荐模型微调。

6. 增量预训练过程中，loss 上升正常么？

通常增量预训练开始的阶段会出现一段时间的 loss 上升，随后慢慢收敛。

7. 增量预训练过程中，lr 如何设置？

学习率是一个很重要的参数，因为 lr 的大小会出现以下问题：

如果 lr 过大，那 loss 值收敛会更困难，旧能力损失的会更大；

如果 lr 过小，那可能难以学到新知识。

当你数据集比较小（例如 100B 以下？），那建议使用较小的学习率。例如可以使用 pre-train 阶段最大学习率的 10%。通常 7B 模型 pre-train 阶段的学习率大概是 3e-4，所以我们可以选择 3e-5。

并且需要根据你的 batch size 做相应缩放。通常 lr 缩放倍数为 batch size 倍数的开方。例如 batch size 增大 4 倍，学习率对应扩大 2 倍即可。

8. 增量预训练过程中，warmup_ratio 如何设置？

warmup_ratio 也很重要。通常 LLM 训练的 warmup_ratio 是 epoch * 1%左右。例如 pre-train 阶段一般只训一个 epoch，则 ratio 是 0.01；SFT 通常 3 个 epoch，ratio 对应为 0.03。

但是如果做 CPT，建议 warmup_ratio 调大一点。如果你的数据集很大，有几百 b，那 warmup 其实不影响最重的模型效果。但通常我们的数据集不会有那么大，所以更小的 ratio 可以让模型“过渡”得更平滑。

学习率和 warmup_ratio 是两个相辅相成的概念，二者通常是成正比的关系。或者说如果你正在用一个较大的学习率，那你或许可以同时尝试增加 warmup 来防止模型“烂掉”。

9. warmup 的步数对大模型继续预训练是否有影响？

warmup 介绍：warmup 是一种 finetune 中常用的策略，指学习率从一个很小的值慢慢上升到最大值；

对比实验设计：使用 不同 4 种不同预热步数（eg：0%, 0.5%, 1%, 2%）来进行实验。

不同预热百分比步数的性能图，上图为下游任务 loss，下图为上游任务 loss

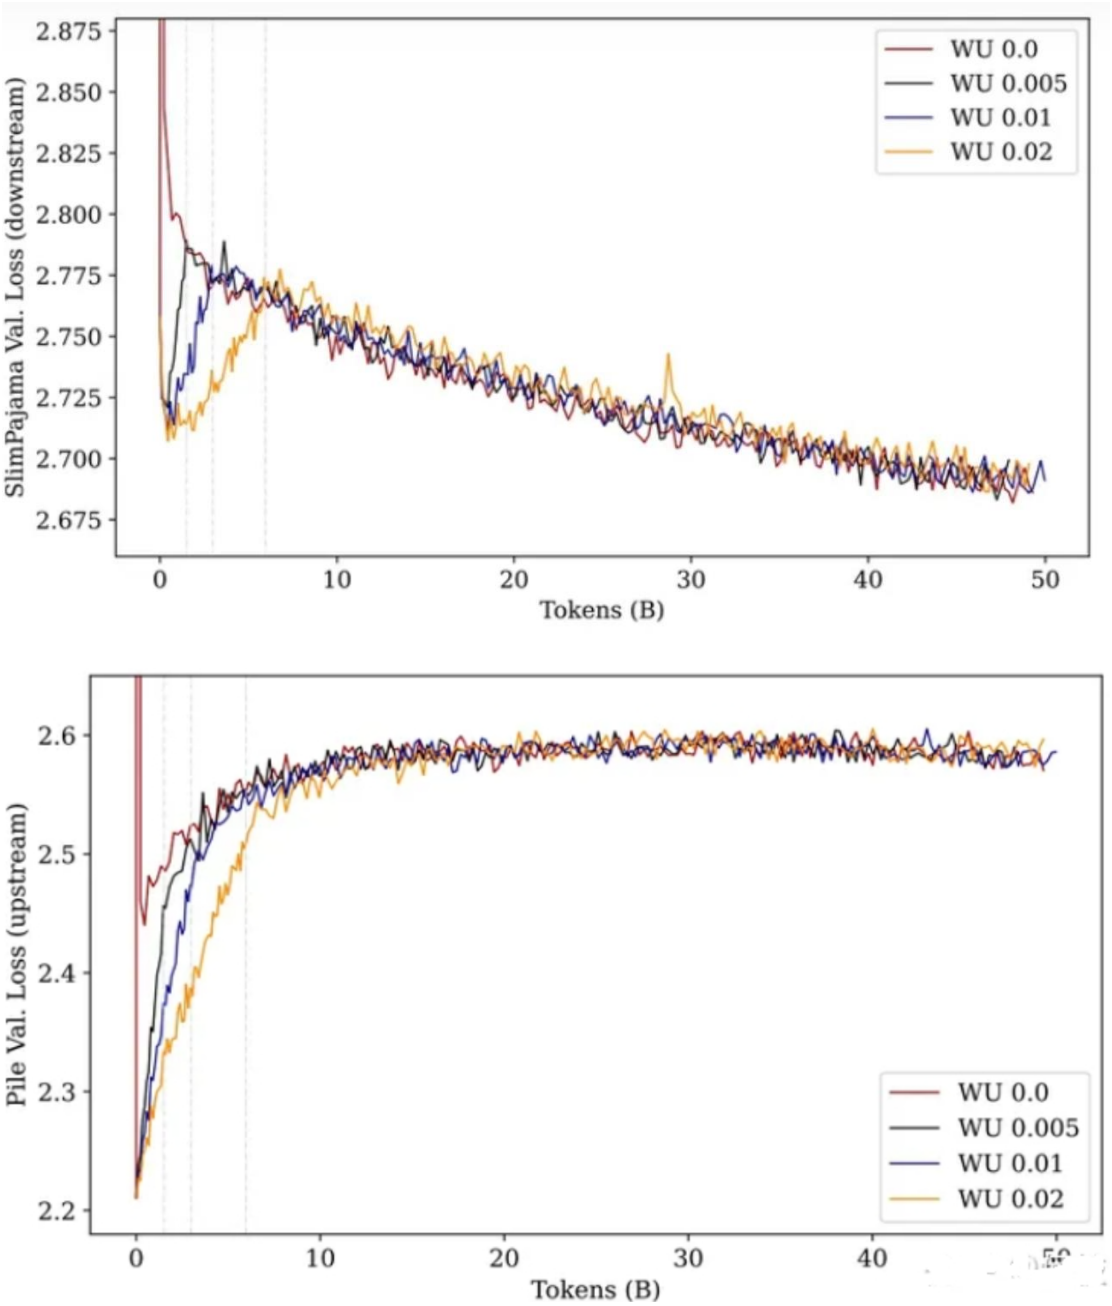

实验结果：当模型经过「充分」训练后，不管多长的预热步数最后的性能都差不多。

注：但，这种前提是「充分训练」，如果只看训练前期的话，使用更长的预热步数（黄色的线），无论是「上游任务」还是「下游任务」，模型的 Loss 都要比其他预热步数要低（下游学的快，上游忘的慢）。

10. 学习率大小对大模型继续预训练后上下游任务影响？

对比实验：使用了 4 种不同的最大学习率进行对比实验

实验结论：

经过充分训练后，学习率越大（紫色），下游性能最好，上游性能最差（忘得最多）。

未经过预训练的模型（蓝色）无论是上游任务还是下游任务，都不如预训练过的模型效果。

注：前期训练，尽管紫色线条在最后的 loss 是最低的，但在前期 loss 会增加的非常大，随后下降。

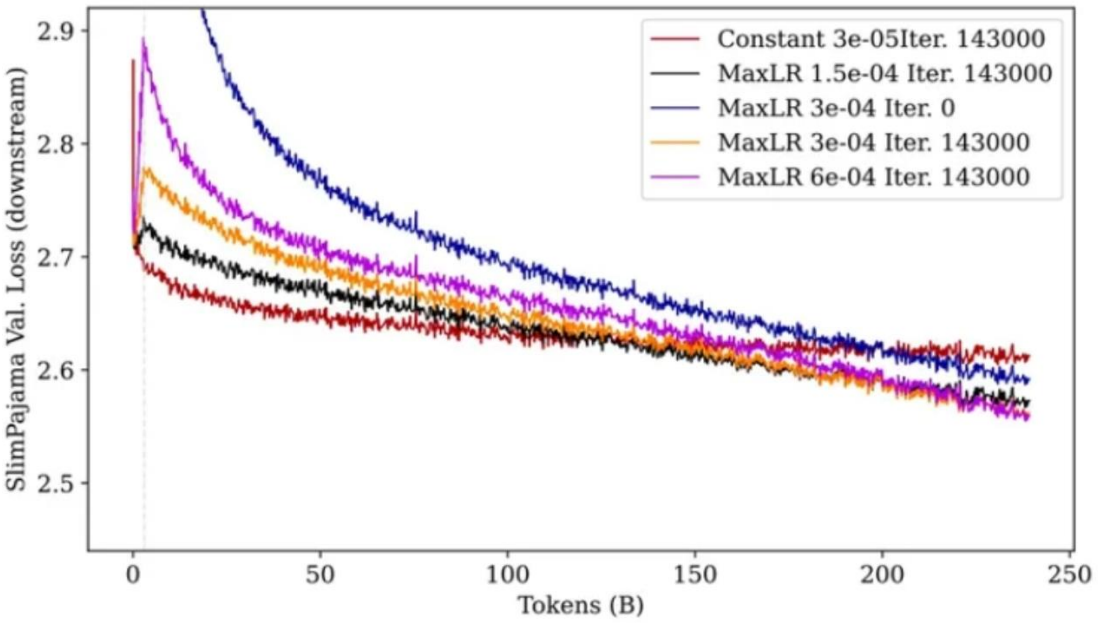

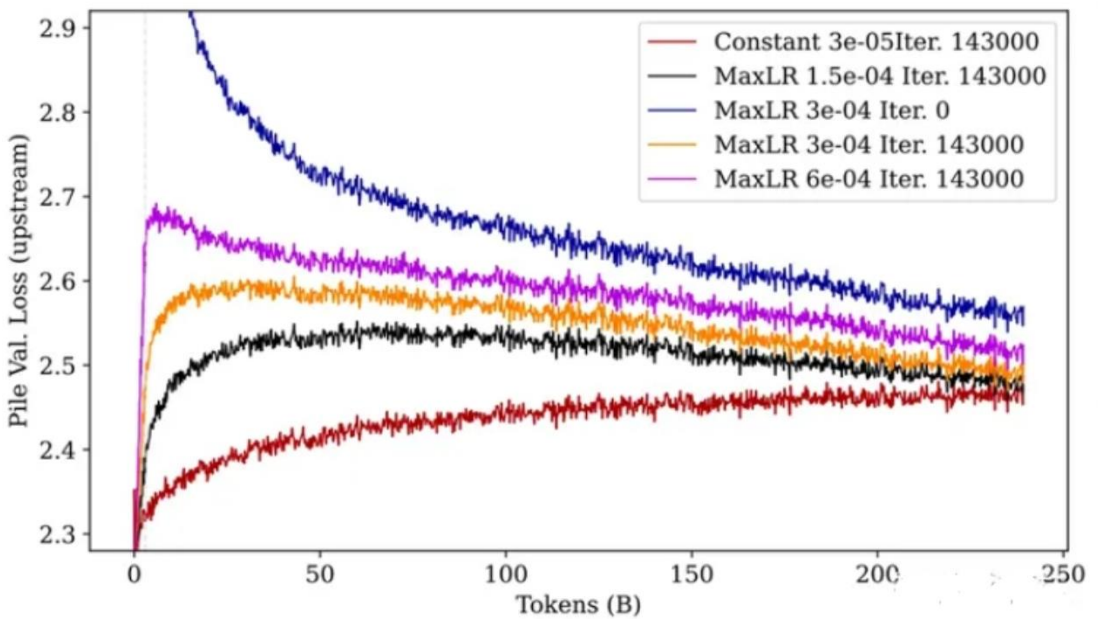

解释一下这里为什么这么关注训练前期，是因为在真实训练中，我们可能不一定会增强图中所示的 250B 这么多的 tokens，尤其是在模型参数很大的情况中。所以，当资源不允许充分训练的情况下，较小的学习率和较长的 warmup 步数可能是一个不错的选择。

11. 在初始预训练中使用 Rewarmup 对大模型继续预训练性能影响？

对比实验：不切换数据集，而是继续在之前的「预训练数据集（The Pile）」上继续训练：

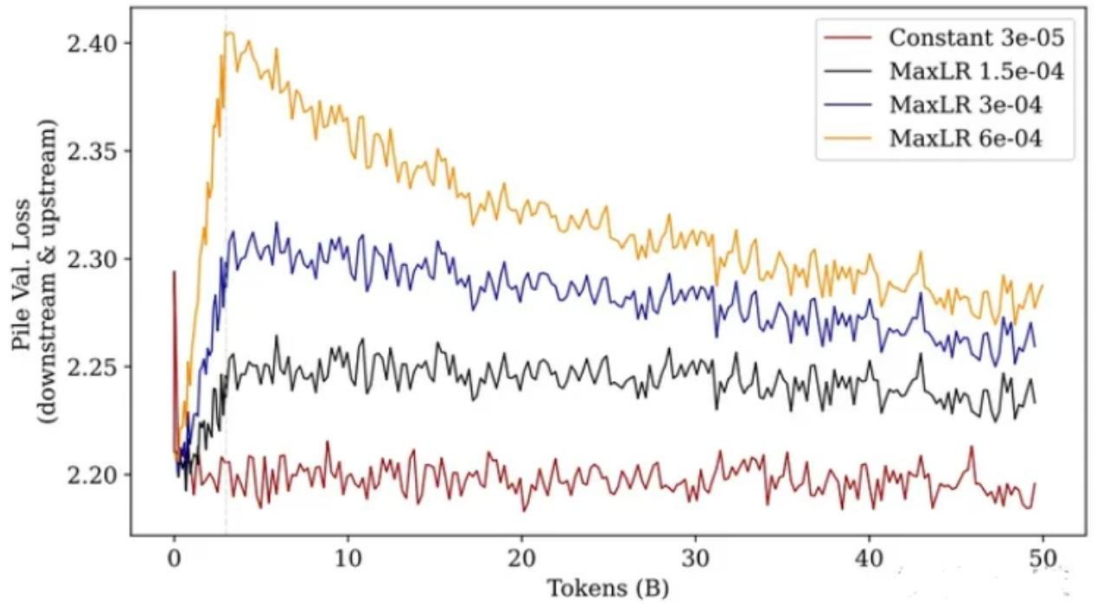

实验结果：无论使用多大学习率的 warmup 策略，效果都不如使用常量学习率。

这进一步证明，在原数据集上使用 warmup 接着训练会造成性能损伤，学习率越大则损伤越大，且这种损伤是无法在后续的训练中被找回的。

注：PS：这里提示我们，当预训练中遇到了训练中断需要继续训练时，我们应该在重新开始训练时将学习率恢复到中断之前的状态（无论是数值还是衰减率）。